评测界面提纲

1. 文件结构

现在整个文件夹分成四个子文件夹：

- evaluation_base是主文件，评测程序放在里面
- data_source是数据接口，用于存放用于构建评测题目的数据，包括视频和题目的元数据（base condition，preference A/B...）
  - 另外还可以存放一个翻译文件，用于把base condition，preference A/B...这些英语翻译成中文，方便后面志愿者理解。目前我使用codex翻译了一版
  - images文件夹存放第一帧图片，我没在服务器里找到，所以目前是空的，需要学姐去服务器上下载下来放进去
  - question_video里我只放了一个模型生成的视频，后续学姐可以把所有视频放进来
- evaluation_packages和evaluation_results初始时是空的，是评测程序后来生成的，evaluation_packages里存放的是用于分发给各个电脑的评测包（志愿者只需跑这个包就可以进行评测了），evaluation_results是存的评测结果，按照评测包编号-评测者性命-评测所用电脑编号 来命名。

具体文件结构如下：

```
评测界面/
├── data_source/                          # 输入数据（只读，不会被修改）
│   ├── question_base/
│   │   ├── final_valid_conditions.jsonl    # 题目元数据（base condition、偏好 A/B）
│   │   ├── translations_zh.tsv             # 可选：中文参考译文（没有则不显示译文）
│   │   └── images/                         # 初始帧图片
│   └── question_video/
│       └── <模型>/<track>/<case>__A|B__<版本>[__seed_N].mp4
│
├── evaluation_base/                      # 程序本体
│   ├── 启动管理界面.cmd                  # 组织者用：打开管理页
│   ├── 启动评测.cmd                      # 学生用：只打开答题页
│   ├── server.py                         # 答题服务 / 命令行入口
│   ├── admin.py  admin.html/js/css       # 管理页（检查数据、分配打包、汇总）
│   ├── index.html  app.js  style.css     # 学生答题页
│   ├── data_import.py                    # 数据检查、创建固定题库、译文核对
│   ├── assignment.py                     # 按编号均衡分题
│   ├── distribution.py                   # 生成各编号的评测包
│   ├── result_io.py                      # 结果导出 / 导入合并
│   ├── report.py                         # 进度总览与导入报告
│   ├── video_playback.py                 # mp4v 等格式转 H.264
│   ├── vendor/                           # 自带的 FFmpeg
│   ├── reports/input_check.md            # 数据检查报告（按类别汇总）
│   └── batches/<题库名>/                 # 固定题库
│       ├── tasks.jsonl  snapshot.json      # 题单 + 校验信息（含译文）
```

```
|       ├── media/                              # 题库视频与图片
|       ├── plans/<方案编号>.json               # 分配方案（汇总时用于核对）
|       ├── merged.sqlite3                      # 汇总后的合并数据库
|       └── aggregate/                          # 共识与 SBPS 汇总结果
|
├── evaluation_packages/<题库名>/<方案编号>/
|   └── evaluation-<题库名>-A01.zip  …      # 发给各电脑的评测包
|
└── evaluation_results/<题库名>/
    └── results-<编号>-<姓名>-….json        # 作答结果（学生发回、主电脑导入）
```

2.评测使用方法

整个评测程序我是分成了两个界面：管理界面和评测界面。

评测时，需要主电脑运行管理界面（只需双击`evaluation_base/ 启动管理界面.cmd`），在管理页检查数据并创建题库，然后填"标注人数"和"每题份数"，系统会自动均衡分题，生成评测包，这些评测包是给志愿者进行评测用的。
然后其他电脑获得到这个评测包后，运行评测（只需双击`evaluation_base/ 启动评测.cmd`），志愿者需要先输入姓名，然后评测。评测结束后在`evaluation_results/`里生成评测结果。
最后把这些评测结果收集起来提交给管理界面进行汇总即可。

详细过程：

组织者（主电脑）：在管理页**检查数据**并**创建题库**，然后填"标注人数"和"每题份数"，系统会自动均衡**分题**。每题由不同的人各做一份，X/Y 顺序提前随机固定，再给每个人单独打一个小评测包，包里只有他要看的视频。
检查数据时，问题按"致命错误 / 错误 / 警告"分类折叠显示。
制作评测包时，会把mp4v 编码的视频自动转成 H.264，不然浏览器无法直接播放。

学生端：解压评测包，双击"启动评测.cmd"，浏览器会自动打开盲评页面（电脑需装 Python 3.10+）。每段视频判断有效性、场景是否保持、是否呈现偏好 A、是否呈现偏好 B。英文条件下方可以显示中文参考译文，以英文原文为准，也能隐藏。
每提交一题自动保存。中途退出后再打开，输入同一姓名就从下一道没做的题继续，换浏览器或清了缓存也不影响；但还没提交的半填答案只存在原浏览器里。

汇总：学生把结果 JSON 发回来，在主电脑一次导入。系统会按分配方案核对，对不上的文件整份拒收，重复导入也不会重复计票。进度总览里能看到每人完成情况、哪些题份数还不够、还缺谁的结果。之后可以计算共识和严格 SBPS，导出原始答案与汇总结果。

更新日志（since 10.15）

10.16更新

完善了对视频编码的转换机制。

模型生成的视频有多种格式，为了让他们都能显示在浏览器上，评测系统会统一将其转换成H.264。

但现在发现个问题，cosmos生成的视频虽然也是H.264，但用的是无损编码常用的 “High 4:4:4 Predictive” 档次，码率约 21–40 MbpsChrome、Edge 和 Windows 自带播放器都不支持这个档次，所以打不开。

现在会自动将其转换为低档次。

10.19更新

更新了对不同题库的results文件的兼容

旧题库的结果现在可以导入新题库了：新旧题库都有、内容完全相同的题会计入，其余的跳过并在导入结果里列出条数。

怎么判断"同一道题"：每道题现在有一个内容指纹，由下面几样算出：

- case、track、模型、版本、seed；
- 共同条件和偏好 A/B 的英文原文；
- 原始视频 A/B 的校验值。

视频转码副本和参考译文不算在内，所以以后换转码方式、改译文，都不会让旧答案失效。

导入旧题库的结果时，系统逐题核对，不再要求整个题库一致：

- **计入**：内容指纹相同的题，原来的 X/Y 对应原样沿用；重复导入不会重复计票。
- **跳过**：新题库已删除的题，以及编号相同但内容变了的题（改了英文措辞，或重新生成了视频）。导入结果里会写明"计入几条、已删除几条、内容已变几条"。
- 旧题库分配方案下各编号的答案也计入题目份数，进度总览里显示为"其他方案"的作答者。

注意：只是初始帧不同但其他都相同的题，我仍然算作是同一题，只单独提示条数。这是因为我测试的时候拿不到初始帧图片（服务器上没找到），后续我们肯定是要加上的。我目前的评测是在没有初始帧图片的情况下做出的（基本不影响判断）

10.20更新

新增了"从已有结果开始"功能：评测时从前的已有评测结果开始评测，方便修改结果或对题库新增题目进行作答。

用法

1. 在管理页"02 在这台电脑开始评测"里，展开"从已有结果开始（可选）"，选一个结果 JSON，再点"启动本机评测"。
2. 点"打开志愿者界面"，姓名会自动填好（就是结果文件里的姓名），勾选规则后开始。
3. 页面直接打开第一道已导入的题，原有答案已经选好，按钮显示"保存修改"。用"上一题 / 下一题 / 跳转题目"逐题看，改了就点"保存修改"。

4. 文件里没有的题（比如新题库新增的），点"继续评测"照常作答。

规则

- 导入时按题目内容核对，规则和跨题库导入一样：只带入新旧题库内容完全相同的题，X/Y 顺序沿用原文件。完成后会提示导入了几题、跳过了几题。
- 开启后，每人题数上限自动放宽到题库总题数，可以从头校验到尾。
- 校验后的结果照常导出，是一份新的结果文件。

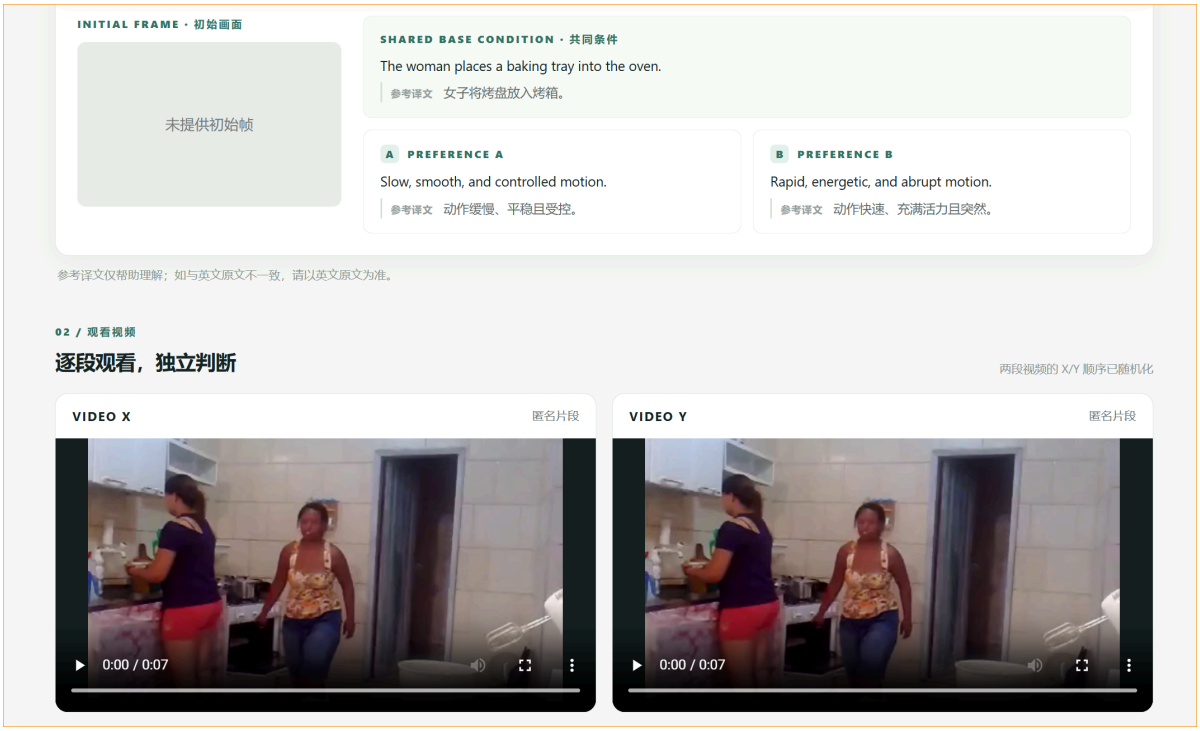
10.22更新

对题目设置做了优化

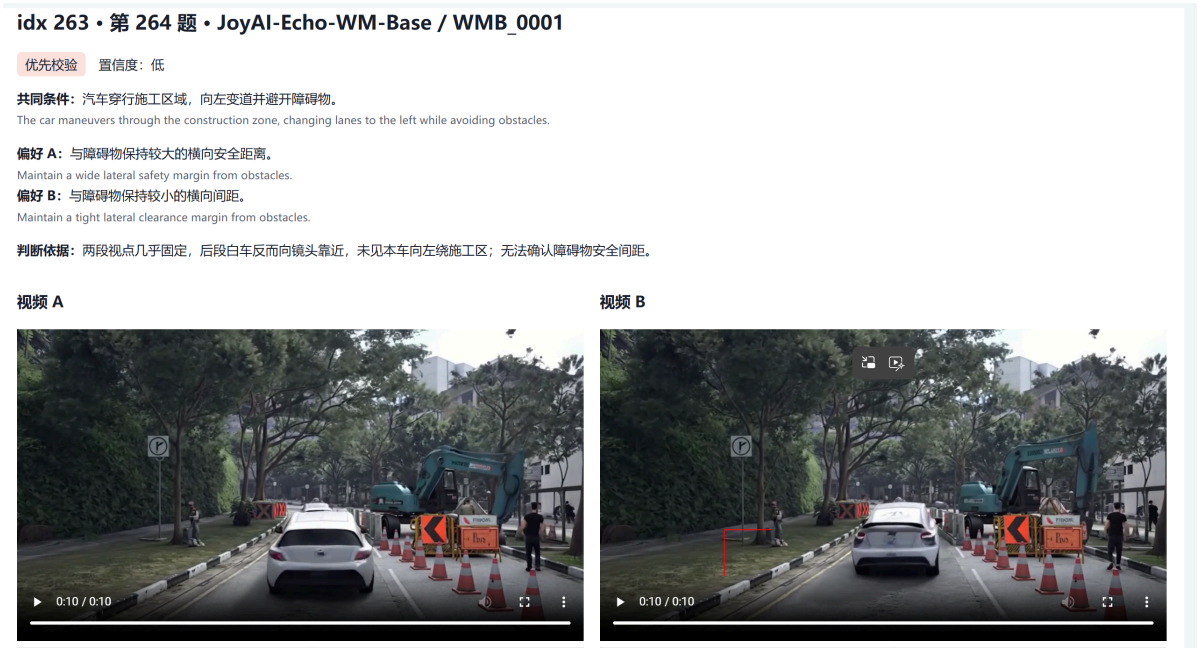
在评测时遇到了一些题目，让我思考我们的题目设置，感觉有点问题。

类型1：基础任务未完成

对于这种题目，比如：

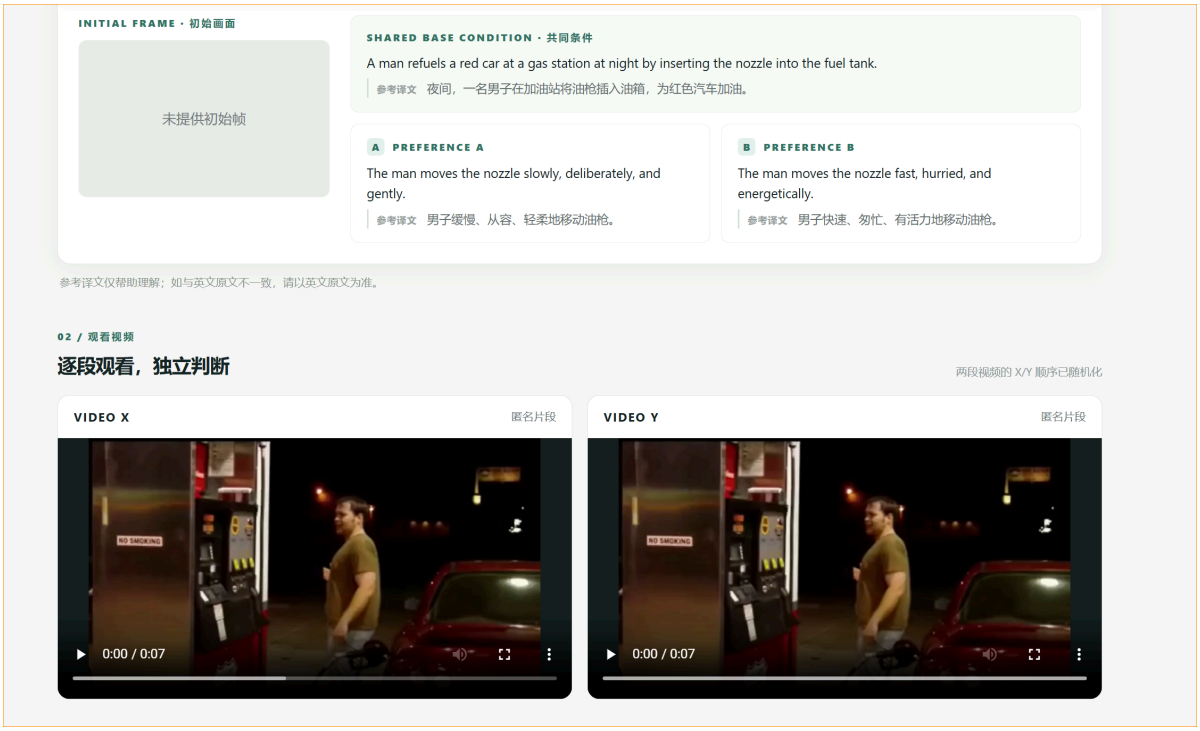


图一，就是这个把烤盘放在烤箱的任务，两个视频感觉都误会了题目，它们生成的视频都是把烤箱里的烤盘拿出来，像是时间倒流一样，而且右边那个视频，我理解她想表示速度快且突兀，但他快的动作不对，不是拿烤盘快，而是在拿完烤盘后快速放在桌子上。这种怎么评价？
再举个例子，

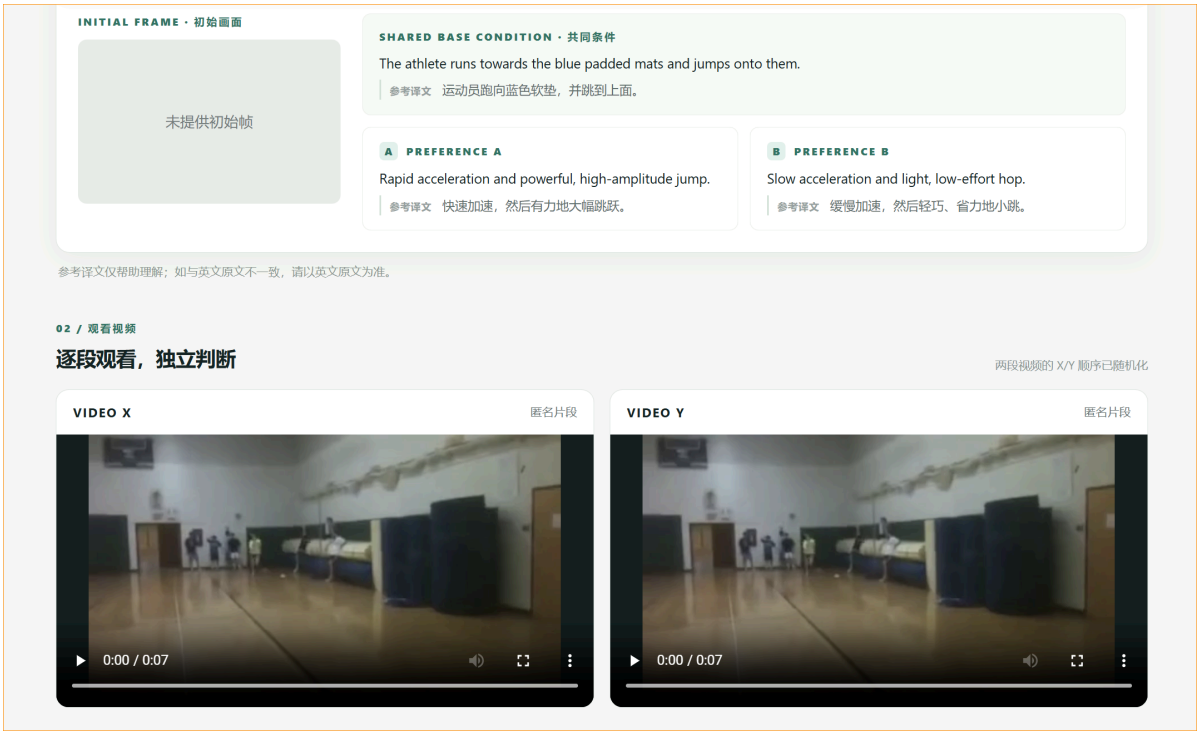


比如图二，图中这道题，题目要求汽车要避障，但是两段视频里，先不提避不避障，汽车竟然是倒着行走的，这种情况该如何处理，学生在我们的评测问题框架下怎么答题才是科学的？

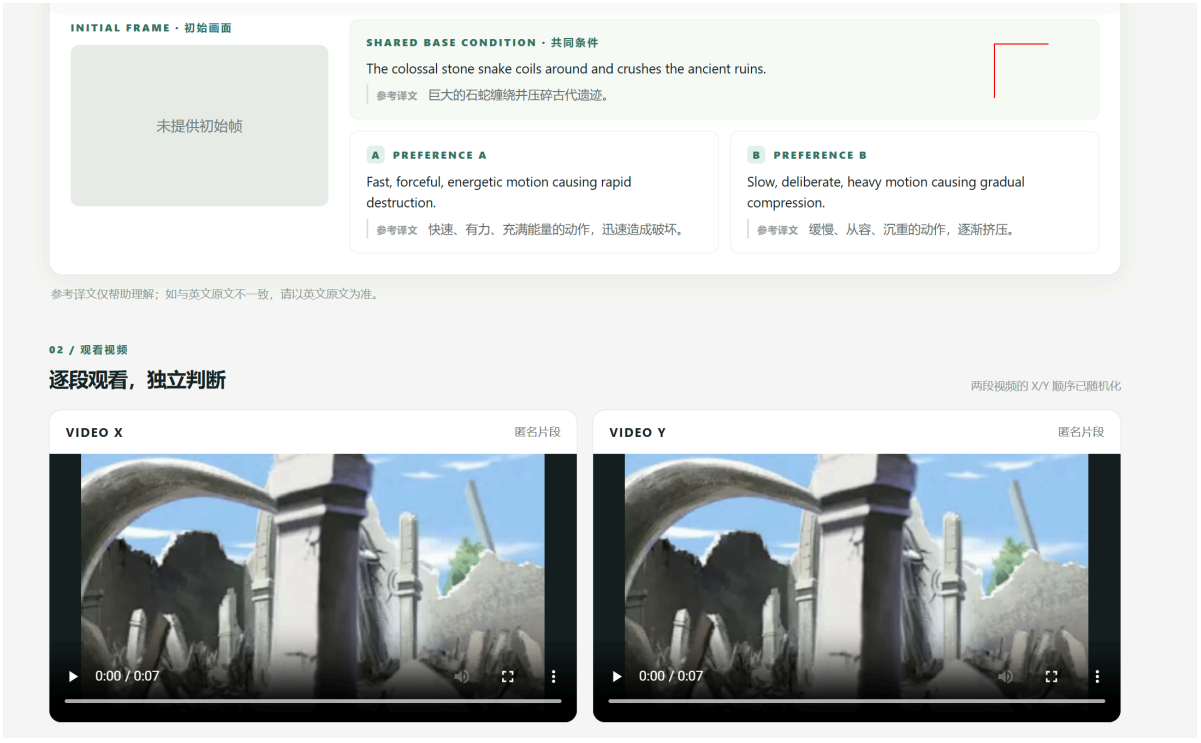
类型2：基础任务完成不彻底



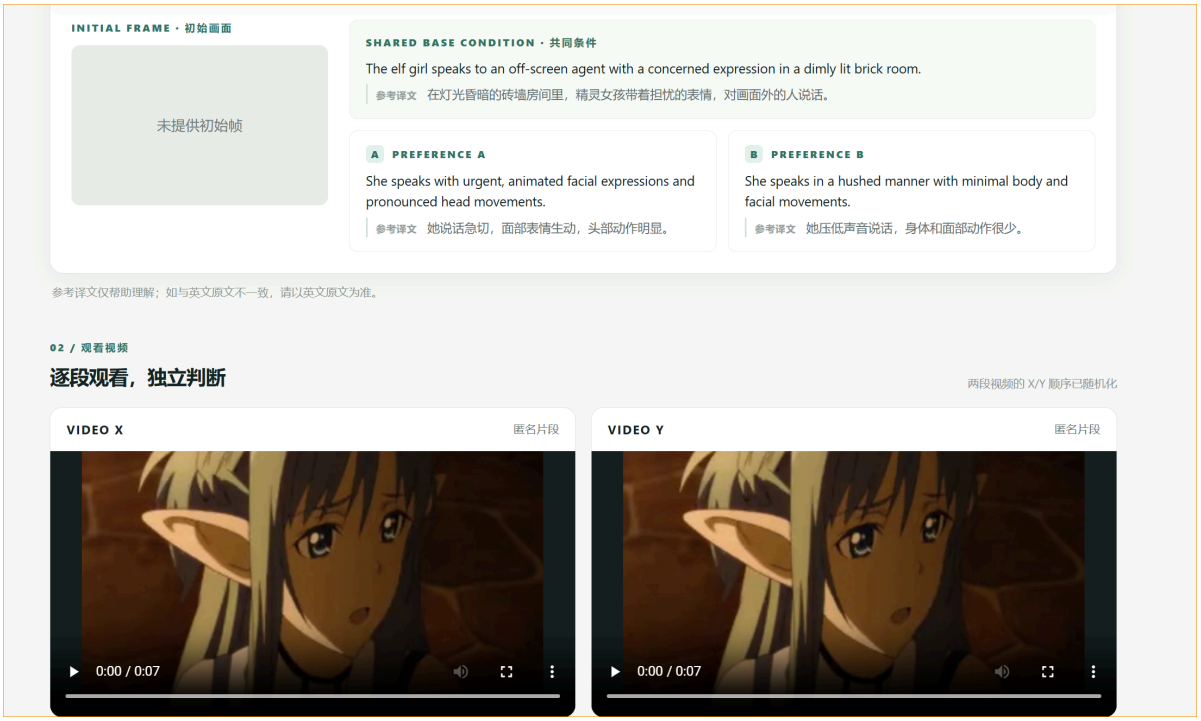
如图1，任务是给汽车加油，两个视频确实都完成了任务，看起来像是在加油，但是都有点小问题，左边视频流程不全，没有从加油站点上取下加油抢的过程，加油枪直接就不知何时已经插在车上了，右边则是物理规律不对，有一瞬间男人直接和加油站重合了，不过除此之外整个流程很清晰，也符合偏好。



还有图2，任务是运动员跑向蓝色软垫，并跳到上面，但是右边视频只完成了一半的任务，只生成了运动员跑的动作，还没来得及生成跳的动作；

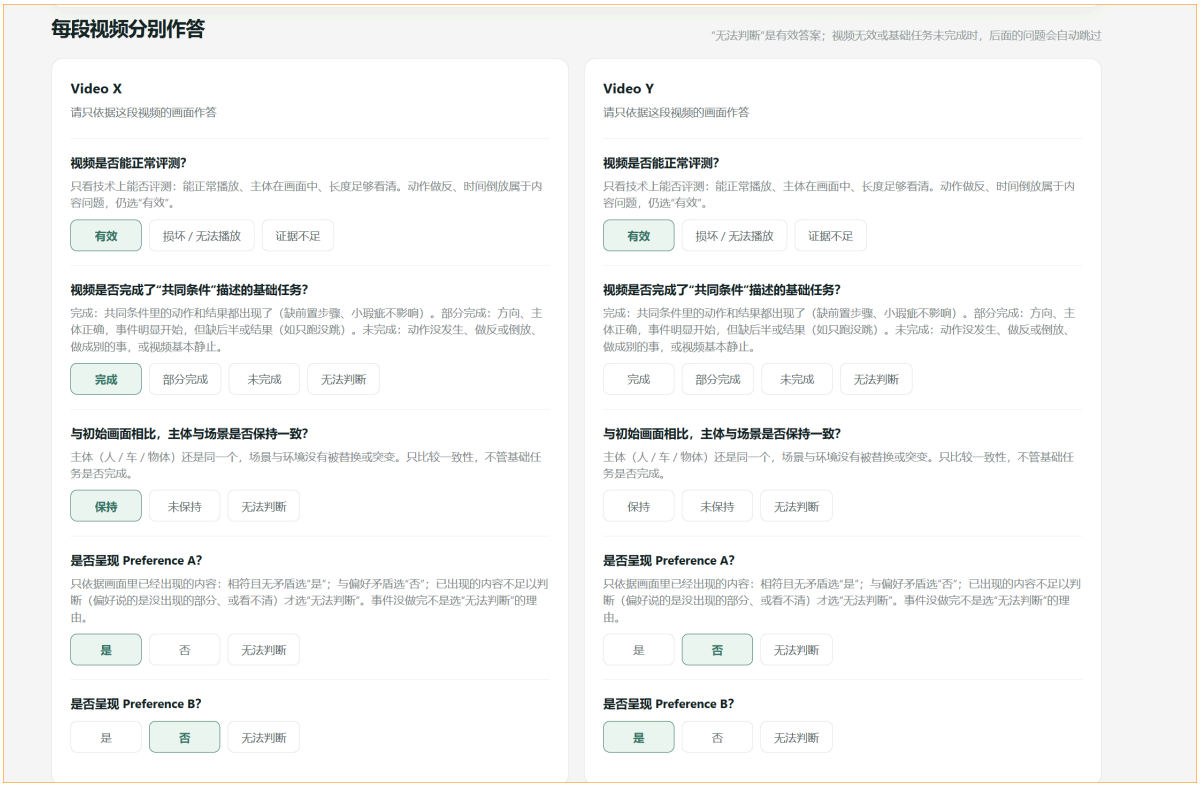


还有图三，任务是巨大的石蛇缠绕并压碎古代遗迹，但是两个视频都是只有缠绕没有压碎，但是偏好生成的是对的。



图四，右边视频直接静止不动。

对评测界面的改动：



如图所示：

1. **把场景与共同事件拆成两问**，一个是问是否完成基础任务，另一个是问一致性
2. 是否完成基础任务 分完成，部分完成 和未完成。 未完成时，后续SBPS直接默认为否
3. 一致性这一问，如果选未保持，则会跳出一个多选题，选择原因



更新了一些答题规则，待学姐确认:

- **画面瑕疵不改变答案。** 穿模、画面不自然本身不影响作答，除非它让所需的画面看不清。这一条在示例里也写了。
- **偏好只依据已出现的画面，作为一个整体答案。** 相符且没有矛盾选"是"，与偏好矛盾选"否"。已出现的内容不足以判断，或偏好说的恰恰是没出现的部分，才选"无法判断"。页面上写明了"事件没做完不是选无法判断的理由"。
  这主要是针对基础任务部分完成的视频

聚合结果时，会有不同的筛选模式:

- `strict_sbps`：只看偏好模式，完成和部分完成都计入，未完成自动失败。这是主指标，没加门槛。
- `strict_sbps_task_done`：再要求两段视频的基础任务共识都是"完成"。
- `strict_sbps_with_gates`：在上一条之外，再要求共同条件共识为"保持"。

评测总结:

最大的感受是，WM的能力太差，生成的视频质量很低，不能很好地完成基础任务，相当多的部分是只完成了部分任务；除此之外视频不够连贯，一致性不能保持，生成的视频变来变去（尤其是部落冲突这种游戏场景）；不太遵守物理规律

因而**SBPS的结果相当之不稳定**，会出现很多的无法判断。这些题目我在判断的时候会非常犹豫，不能说没表现出偏好，但是偏好不完全对，或者说表现偏好的方式不合适；视频本身不太对；

但如果去做相对偏好判断，这些视频两两之间的偏好比较还是非常明显的，这样的结果会稳定得多。

- 所有题目里，皇室战争这种界面复杂的游戏场景，ai生成的视频几乎没一个是对的；3D场景的游戏的表现会好很多。
- 所有模型里，SANA-WM生成的视频最差，尤其是机械臂视频，几乎无法辨别，更别说去看偏好，所以题目里我选了非常多的“无法判断”